

# MPEI 2015-2016

# Aula 15 – Cadeias de Markov

4 Novembro 2015

# ?!

- O que esteve na origem do grande sucesso inicial da Google ?
- O que tem em comum esse sucesso com a capacidade de interagir por voz com computadores, robôs e smartphones ?
  - No reconhecimento de fala ?
  - Na síntese de fala ?

# Exemplo 1

- Suponhamos que em cada dia que têm aulas de MPEI acordam e decidem se vêm ou não à aula.
- Se vieram à aula anterior, a probabilidade de virem é 70%; se faltaram à anterior, essa probabilidade é 80%.
- Algumas questões:
  - Se vieram à aula esta quarta, qual a probabilidade de virem na aula de **QUARTA** da próxima semana ?
  - Assumindo que o semestre tem duração infinita (que horror!), qual a percentagem aproximada de aulas a que estariam presentes ?

# Exemplo 2

- Dividir a turma em 3 grupos A, B e C no início do semestre
- No final de cada aula:
- $\frac{1}{3}$  do grupo A vai para o B e outro  $\frac{1}{3}$  do grupo A vai para o grupo C
- $\frac{1}{4}$  do grupo B vai para A e  $\frac{1}{4}$  de B vai para C
- $\frac{1}{2}$  do grupo C vai para o grupo B
- Como ficarão os grupos ao fim de n aulas ?

# Exemplo 3 – “Pub Crawl”

- Bares junto a uma conhecida Universidade:



# Outro exemplo

- Passeio aleatório (random walk)

Lançar moeda

Cara Coroa Coroa ... Cara ...

# Muitas áreas de aplicação

- Muitas vezes estamos interessados na transição de algo entre certos estados.
- Exemplos:
  - Movimento de pessoas entre regiões
  - Estado do tempo
  - Movimento entre as posições num jogo de Monopólio
  - Pontuação ao longo de um jogo
  - Estado de Filas de atendimento



# Princípios básicos

# Processos estocásticos

- Lidam com a dinâmica da teoria de probabilidades
- O conceito de processo estocástico estende o conceito de variável aleatória
- Uma v.a.  $X$  mapeia um acontecimento  $s \in \Omega$  num número  $X(s)$
- O processo mapeia o evento para números diferentes em tempos diferentes
  - O que implica que em lugar de termos um número  $X(s)$  temos  $X(t, s)$
  - Sendo  $t \in T$  geralmente um conjunto de tempos

# Processos estocásticos

- Se fixarmos  $s$ ,  $X(t)$  é uma função real do tempo
- $X(t, s)$  pode então ser vista como uma colecção de funções no tempo
- Se fixarmos  $t$  temos uma função  $X(s)$  que depende apenas de  $s$ , ou seja uma variável aleatória
- Um nome alternativo é processos aleatórios

# Classificação de processos estocásticos

- Podem ser classificados segundo o parâmetro  $t$  e os valores que  $X(t, s)$  pode assumir (estados do processo)
- Quanto a  $t$ :
  - Tempo contínuo: Se  $T$  é um intervalo contínuo
  - Tempo discreto: Se  $T$  é um conjunto contável
    - Também chamada sequência aleatória e representada por  $X[n]$
- Quanto ao conjunto de estados ( $E$ ):
  - Contínuo
  - Discreto

# Definição

- Um **processo de Markov** é um processo estocástico em que a probabilidade de o sistema estar num estado específico num determinado período de observação depende apenas do seu estado no período de observação imediatamente precedente
  - O futuro apenas depende do presente e não do passado

# Tipos de processos de Markov

- Discretas/contínuas

		Espaço de estados	
		Discreto	Contínuo
Tempo	Discreto	<b>Cadeia de Markov tempo discreto</b>	Processo de Markov em tempo discreto
	Contínuo	Cadeia de Markov tempo contínuo	Processo de Markov em tempo contínuo

- Focaremos a nossa atenção em cadeias de Markov de tempo discreto

# Cadeias de Markov discretas

- $X_n$ : estado após  $n$  transições
  - Pertence a um conjunto finito,
    - Em geral  $\{1, 2, \dots, m\}$
  - $X_0$  é dado ou aleatório

# Questões comuns relativas a cadeias de Markov

- Qual a probabilidade de transição entre dois estados em  $n$  observações ?
- Existe algum equilíbrio ?
- Existe uma estabilidade a longo prazo ?



# Propriedade/Suposição de Markov

- Probabilidade de **transição do estado  $i$  para o estado  $j$** :
- $p_{ji} = P(X_{n+1} = j | X_n = i)$   
$$= P(X_{n+1} = j | X_n = i, X_{n-1}, \dots, X_0)$$
- Quando estas probabilidades  $p_{ji}$  não dependem de  $n$  a cadeia diz-se **homogénea**
  - Focaremos a nossa atenção neste tipo de cadeias de Markov


# Propriedade/Suposição de Markov

- $P(X_0 = x_0, X_1 = x_1, X_2 = x_2 \dots) = ?$

$$= P(X_0 = x_0) P(X_1 = x_1 | X_0 = x_0) P(X_2 = x_2 | X_0 = x_0, X_1 = x_1) \dots$$

$$= P(X_0 = x_0) P(X_1 = x_1 | X_0 = x_0) P(\textcolor{blue}{X}_2 = \textcolor{blue}{x}_2 | \textcolor{blue}{X}_1 = \textcolor{blue}{x}_1) \dots$$

- O futuro é independente do passado, dado o presente
- O processo “não tem memória”



# Especificação de uma cadeia

- Identificar os **estados** possíveis
- Identificar as **transições** possíveis
- Identificar as **probabilidades de transição**

# Aplicando ao exemplo 1 – faltar ou não faltar à aula


- Estados ?
- Transições ?
- Probabilidades de transição ?

# Aplicando ao exemplo 1 – faltar ou não faltar à aula

- Estados ?
  - 2: {faltar, não faltar}
- Probabilidades de transição ?
  - Faltar-> não faltar : 0,8
  - Não faltar -> faltar : 0,3
- Transições ?
  - Faltar-> não faltar
  - Não faltar -> faltar
  - Faltar -> faltar : 0,2
  - Não faltar -> não faltar: 0,7

# Matriz de transição

- É usual representar as probabilidades de transição através de uma matriz, chamada de matriz de transição
- Tendo o sistema  $n$  estados possíveis, para cada par  $i, j$  fazemos  $t_{ji}$  igual à probabilidade de mudar **do estado  $i$  para o estado  $j$** .
- A matriz  $T$  cujo valor na posição linha =  $j$ , coluna =  $i$  é  $t_{ji}$  é a **matriz de transição**



- Nota: Alguns autores adoptam  $t_{ij}$  como a probabilidade de mudar do estado  $i$  para o estado  $j$

# Matriz T do Exemplo 1

- $T = \begin{pmatrix} ? & ? \\ ? & ? \end{pmatrix}$
- Considerando estado 1 “não faltar”, temos
- $T = \begin{matrix} \text{não faltar} & \rightarrow & (0,7 & 0,8) \\ \text{faltar} & \rightarrow & (0,3 & 0,2) \end{matrix}$


# Matriz T do Exemplo 2

$$T = \begin{array}{c|ccc} & A & B & C \\ \hline A & ? & ? & ? \\ B & ? & ? & ? \\ C & ? & ? & ? \end{array}$$



## Matriz T do Exemplo 2


$$T = \begin{matrix} & \begin{matrix} A & B & C \end{matrix} \\ \begin{matrix} A \\ B \\ C \end{matrix} & \begin{matrix} 1/3 \\ 1/3 \\ 1/3 \end{matrix} \end{matrix}$$



Futuro Estado

## Matriz T do Exemplo 2

$$T = \begin{array}{c|ccc} & A & B & C \\ \hline A & 1/3 & 1/4 & 0 \\ B & 1/3 & 1/2 & 1/2 \\ C & 1/3 & 1/4 & 1/2 \end{array}$$



Futuro Estado

# Matriz T é estocástica


- A matriz de transição reflecte propriedades importantes das probabilidades:
  - Todas as entradas são não-negativas
  - Os valores em **cada COLUNA** somados dão sempre resultado 1
- Devido a estas propriedades a matriz é denominada de **matriz estocástica**

# Representação gráfica da cadeia

- Adequada e possível para número de estados pequeno
- Nós: representam todos os estados
- Setas: para todas as transições permitidas (one-step)
  - Ou seja, seta entre  $i$  e  $j$  apenas de  $p_{ji} > 0$

# Representação gráfica da cadeia

- Exemplo:



# Simulação / Visualização dinâmica

- Estão disponíveis online formas de visualizar as transições entre estados ao longo do tempo ...
- Um desses exemplos é **Markov Chains - A visual explanation by [Victor Powell](http://setosa.io/blog/2014/07/26/markov-chains/index.html)**

- <http://setosa.io/blog/2014/07/26/markov-chains/index.html>

Que inclui:

- <http://setosa.io/markov/index.html#%7B%22tm%22%3A%5B%5B0.5%2C0.5%5D%2C%5B0.5%2C0.5%5D%5D%7D>

- Para usar precisamos apenas de introduzir a matriz  $T$ 
  - Que define o número de estados, quais as transições possíveis e as probabilidades associadas a essas transições

# Simulando os nossos exemplos

- Exemplo 1:
  - Matriz:  
[ [ 0.7, 0.3],  
[ 0.8, 0.2] ]
  - <http://setosa.io/markov/index.html#%7B%22tm%22%3A%5B%5B0.7%2C0.3%5D%2C%5B0.8%2C0.2%5D%5D%7D>
- Exemplo 2:
  - Matriz:  
[ [0.33,0.33,0.34],  
[0.25,0.5,0.25],  
[0,0.5,0.5]]
- Outro exemplo
  - [ [0,1,0,0],  
[0,0,1,0],  
[0,0,0,1],  
[0.2,0.3,0.3,0.2]]
  - O que vamos ver ?
  - Acesso directo:  
<http://setosa.io/markov/index.html#%7B%22tm%22%3A%5B%5B0%2C1%2C0%2C0%5D%2C%5B0%2C0%2C1%2C0%5D%2C%5B0%2C0%2C0%2C1%5D%2C%5B0.2%2C0.3%2C0.3%2C0.2%5D%5D%7D>