

MPEI 2015-2016

Aula 16 – Cadeias de Markov (continuação)

5/6 Novembro 2015

Assuntos principais da aula anterior

- Noção de processo estocástico
- Cadeias de Markov
- Propriedade de Markov
- Matriz de transição T
- Representação gráfica

Demos

- **Wolfram:**
 - **Finite-State, Discrete-Time Markov Chains**
 - <http://demonstrations.wolfram.com/ATwoStateDiscreteTimeMarkovChain/>
 - <http://demonstrations.wolfram.com/FiniteStateDiscreteTimeMarkovChains/>

Estado da cadeia num determinado instante

- O **estado** de uma cadeia de Markov com n estados no tempo (time step) k é dado pelo **vector estado**

$$\mathbf{x}^{(k)} = \begin{pmatrix} p_1^{(k)} \\ p_2^{(k)} \\ \vdots \\ p_n^{(k)} \end{pmatrix}$$

- Onde $p_j^{(k)}$ é a probabilidade de o sistema estar no estado j no tempo k

Vector estado/probabilidade

- Considerando o exemplo 1:
- Suponhamos que após 10 aulas a probabilidade de faltar e não faltar são iguais
- Então o vector representativo do estado (state vector) seria:

$$\mathbf{x}^{(10)} = \begin{pmatrix} 0,5 \\ 0,5 \end{pmatrix}$$

- Este vector também se designa por **vector de probabilidade**
 - Todos elementos não-negativos
 - Soma dos elementos igual a um

Exemplo 2

- Supondo que começávamos com 20 estudantes no grupo A e 10 estudantes nos outros dois grupos, o vector relativo ao estado inicial seria

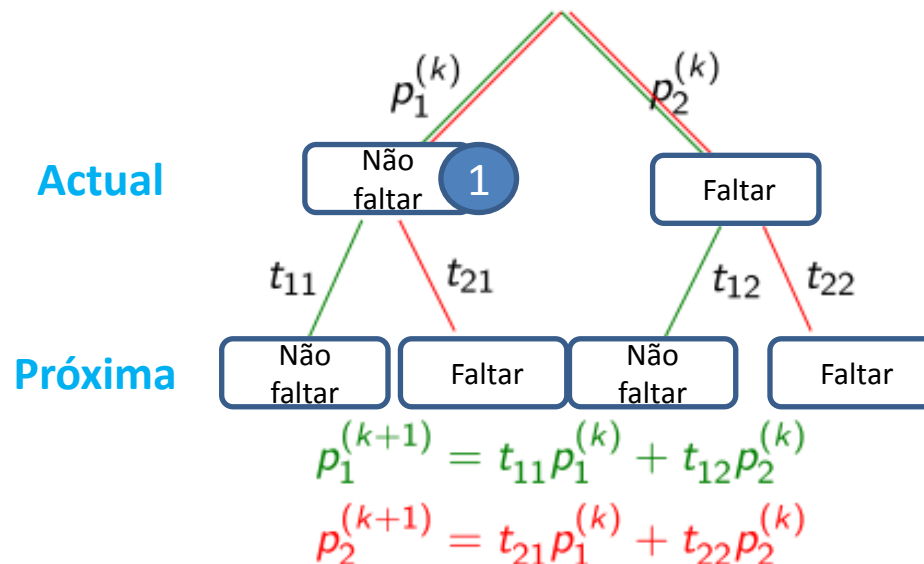
- $\mathbf{x}^{(0)} = \begin{pmatrix} 0,5 \\ 0,25 \\ 0,25 \end{pmatrix}$

Vector estado após uma transição

- Como obter $\mathbf{x}^{(k+1)}$?
- O vector de estado $\mathbf{x}^{(k+1)}$ no período de observação $k + 1$ pode ser determinado a partir do vector $\mathbf{x}^{(k)}$ através de:
- $\mathbf{x}^{(k+1)} = T\mathbf{x}^{(k)}$
- Que resulta da probabilidade condicional:
- $P(\text{estado } j \text{ em } t = k + 1)$
- $= \sum_{i=1}^n P(\text{transição do estado } i \text{ para o } j)P(\text{estado } i \text{ em } t = k)$

Exemplo de aplicação – Exemplo 1

- De que forma depende a probabilidade de ir à aula seguinte da probabilidade de estar na aula actual ?



Estado após múltiplas transições

- Ataquemos agora problemas do “tipo”:
 - Qual a **probabilidade de transição entre dois estados em n observações/transições ?**
- Exemplo 1:
 - Qual a probabilidade dos que estiveram na aula de uma quarta virem à aula na quarta seguinte
 - Assumindo as probabilidades do nosso exemplo !
 - Tendo em conta que temos aulas Quarta e Quinta

Equações de Chapman-Kolmogorov


- Definindo a transição em n passos p_{ji}^n como a probabilidade de **um processo no estado i se encontrar no estado j após n transições** adicionais. Ou seja:
- $p_{ji}^n = P(X_{n+k} = j | X_k = i), \quad n \geq 0, i, j \geq 0$
- Obviamente $p_{ji}^1 = p_{ji}$
- As **equações de Chapman-Kolmogorov** permitem calcular estas probabilidades

$$p_{ji}^{n+m} = \sum_{k=0}^{\infty} p_{ki}^n p_{jk}^m \quad \forall n, m \geq 0, \forall i, j$$

Interpretação

- É fácil de compreender se tivermos em conta que $p_{ki}^n p_{jk}^m$ representa a probabilidade de:
 - Começando em i o processo ir para o estado j em $n + m$ transições..
 - Através de um caminho que o leva ao estado k na transição n
- Logo, somando para todos os estados intermédios k obtém-se a probabilidade de estar no estado j ao fim de $n + m$ transições

Interpretação



“Demonstração” Eqs. Chapman-Kolmogorov

- $p_{ji}^{n+m} = P(X_{n+m} = j | X_0 = i)$
- $= \sum_{k=0}^{\infty} P(X_{n+m} = j, X_n = k | X_0 = i)$
- $= \sum_{k=0}^{\infty} P(X_{n+m} = j | X_n = k) P(X_n = k | X_0 = i)$
- $\sum_{k=0}^{\infty} p_{jk}^m p_{ki}^n$

Em termos de matrizes

- Se usarmos $\mathbf{T}^{(n)}$ para representar a matriz com as probabilidades de n transições, a equação anterior transforma-se em:


$$\mathbf{T}^{(n+m)} = \mathbf{T}^{(n)} . \mathbf{T}^{(m)}$$

Em que o “.” significa multiplicação de matrizes

- Desta equação obtém-se facilmente:

$$\mathbf{T}^{(2)} = \mathbf{T}^{(1+1)} = \mathbf{T} . \mathbf{T} = \mathbf{T}^2$$

- E por indução $\mathbf{T}^{(n)} = \mathbf{T}^{(n-1+1)} = \mathbf{T}^{n-1} . \mathbf{T} = \mathbf{T}^n$
 - Ou seja, a matriz de transição relativa a n transições pode ser obtida multiplicando \mathbf{T} por si própria n vezes



Aplicação ao Exemplo 1

- Voltando a uma questão colocada no início da aula ...
- *Se vieram à aula esta quarta, qual a probabilidade de virem na aula de **QUARTA** da próxima semana ?*
- Solução:
- Temos $\mathbf{x}^{(0)} = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$, significando “não faltar”
- Pretendemos $\mathbf{x}^{(2)}$, 0= hoje

...

- $\mathbf{x}^{(2)} = T\mathbf{x}^{(1)} = T(T\mathbf{x}^{(0)}) = T^2\mathbf{x}^{(0)}$

$$= \begin{pmatrix} 0.7 & 0.8 \\ 0.3 & 0.2 \end{pmatrix}^2 \begin{pmatrix} 1 \\ 0 \end{pmatrix} = \begin{pmatrix} 0.7 & 0.8 \\ 0.3 & 0.2 \end{pmatrix} \begin{pmatrix} 0.7 \\ 0.3 \end{pmatrix} = \begin{pmatrix} 0.73 \\ 0.27 \end{pmatrix}$$

- Ou seja 73% de probabilidade de virem na próxima Quarta

Terminologia



Tipos de estados

Tipos de matrizes de transição

...


Acessibilidade de um estado

- Possibilidade de ir do estado i para o estado j (existe caminho na cadeia de i para j).



Estados comunicantes

- Dois estados comunicam se ambos são acessíveis a partir do outro.




- Um sistema é não redutível (irreducible) se todos os estados comunicam
- Classe:** conjunto de estados que comunicam entre si

Estado recorrente

- Um estado s_i é um **estado recorrente** se o sistema voltará sempre a ele depois de sair dele.
- De uma forma mais formal: s_i é um **estado recorrente** se, para todos os estados s_j , a existência de um inteiro r_j tal que $p_{ji}^{(r_j)} > 0$ implica que existe um inteiro r_i tal que $p_{ij}^{(r_i)} > 0$
- Um estado não recorrente é transiente

Estados recorrentes ?



- Os 3 estados são recorrentes


Estado transiente

- Um estado é transiente se **existe um outro estado qualquer para o qual o** processo de Markov **pode transitar, mas do qual o processo não pode retornar**
- Ou seja, se existe um estado s_j e um inteiro l tal que $p_{ji}^{(l)} \neq 0$ e $p_{ij}^{(r)} = 0$ para $r = 0, 1, 2, \dots$
- A probabilidade destes estados tende para zero quando n tende para infinito
 - Pois apenas são visitados um número finito de vezes


Estado periódico

- Um estado é **periódico** se apenas se pode regressar a ele após um número fixo de transições superior a 1 (ou múltiplos desse número).
- Formalizando:
 - Um estado recorrente s_i diz-se **periódico** se existe um inteiro $c > 0$ tal que $p_{ii}^{(r)}$ é igual a zero para todos os valores de r excepto $r = c, 2c, 3c, \dots$

Estado periódico



Todos estados visitados em múltiplos de 3 iterações




Todos estados visitados em múltiplos de 3 iterações

- Um estado não periódico é **aperiódico**
 - Como era de esperar!

Estado absorvente

- Um estado **absorvente** é um **estado do qual não é possível sair** (ou seja transitar para outro estado)
- Uma cadeia é absorvente se tiver pelo menos um estado absorvente




- Os estados 0 e 4 são absorventes

Aplicação dos conceitos

- Exemplo:

State	0	1	2	3
0	0	X	X	0
1	X	0	0	0
2	0	0	0	X
3	X	0	0	X



- Todos os pares de estados comunicam, formando um única classe recorrente
 - Os estados são aperiódicos
- Em consequência o processo é aperiódico e irreduzível

O que acontece ao fim de muitas
transições ?

Potências de T quando $n \rightarrow \infty$

- Exemplo 2:
- Vejamos o comportamento de T^n ao aumentar n...

$$T = \begin{pmatrix} 0.333333 & 0.25 & 0. \\ 0.333333 & 0.5 & 0.5 \\ 0.333333 & 0.25 & 0.5 \end{pmatrix}$$

$$T^2 = \begin{pmatrix} 0.194444 & 0.208333 & 0.125 \\ 0.444444 & 0.458333 & 0.5 \\ 0.361111 & 0.333333 & 0.375 \end{pmatrix}$$

$$T^3 = \begin{pmatrix} 0.175926 & 0.184028 & 0.166667 \\ 0.467593 & 0.465278 & 0.479167 \\ 0.356481 & 0.350694 & 0.354167 \end{pmatrix}$$

$$T^4 = \begin{pmatrix} 0.17554 & 0.177662 & 0.175347 \\ 0.470679 & 0.469329 & 0.472222 \\ 0.353781 & 0.353009 & 0.352431 \end{pmatrix}$$

$$T^5 = \begin{pmatrix} 0.176183 & 0.176553 & 0.176505 \\ 0.470743 & 0.47039 & 0.470775 \\ 0.353074 & 0.353057 & 0.35272 \end{pmatrix}$$

$$T^6 = \begin{pmatrix} 0.176414 & 0.176448 & 0.176529 \\ 0.470636 & 0.470575 & 0.470583 \\ 0.35295 & 0.352977 & 0.352889 \end{pmatrix}$$

Continuando... (em Matlab)

% n =10

Tn =

0.1765 0.1765 0.1765

0.4706 0.4706 0.4706

0.3529 0.3529 0.3529


% n=100

Tn =

0.1765 0.1765 0.1765


0.4706 0.4706 0.4706

0.3529 0.3529 0.3529



Exemplo 1

```
Tn=eye(2)
pij=[];
for n=1:10
    Tn=Tn*T;
    pij=[ pij Tn(:)]
    plot(pij')
    drawnow
end
Tn
```



Tn =

0.7273	0.7273
0.2727	0.2727

Questões ?

- Converge ?
- Para quê ?

Equilíbrio

- As cadeias dos nossos exemplos atingem um equilíbrio.
- Quando isso acontece a probabilidade de qualquer estado torna-se constante independentemente do passo (step) e das condições iniciais
- Para analisar essa situação é necessário considerar um certo tipo de cadeias de Markov...

Matriz/ Processo regular

- A matriz de transição (ou o processo de Markov correspondente) é **regular** se alguma potência da matriz tem todos os valores não-nulos.
 - Existe uma **probabilidade de mudar de qualquer estado para qualquer estado**
- Qualquer matriz de transição sem elementos nulos é uma matriz regular.
- No entanto, uma matriz contendo elementos nulos pode ser regular.
 - Por exemplo: $T = \begin{bmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ 0,5 & 0,5 & 0 \end{bmatrix}$

...

- No caso de matrizes com elementos nulos, pode verificar-se se é regular substituindo os elementos não-nulos por “X” e calculando potências sucessivas
- No nosso exemplo:

$$\bullet \quad T = \begin{bmatrix} 0 & X & 0 \\ 0 & 0 & X \\ X & X & 0 \end{bmatrix}, T^2 = \begin{bmatrix} 0 & 0 & X \\ X & X & 0 \\ 0 & X & X \end{bmatrix} \dots, T^8 = \begin{bmatrix} X & X & X \\ X & X & X \\ X & X & X \end{bmatrix}$$

Cadeia **ergódica**

- Uma cadeia de Markov diz-se ergódica se é possível efectuar transições de qualquer estado para qualquer outro estado
- Em consequência, uma cadeia regular é também ergódica

Cadeia ergódica

- No entanto, **nem todas as cadeias ergódicas são regulares**
 - Exemplo: se de um determinado estado se pode transitar para alguns estados apenas num número par de transições e para outros num número ímpar de transições, então todas as potências da matriz de transição terão elementos nulos

$$T = \begin{bmatrix} 0 & 1 & 0 \\ 0,5 & 0 & 0,5 \\ 0 & 1 & 0 \end{bmatrix}$$

...

- Potências pares

```
>> T^31
```

```
ans =
```

```
    0  1.0000    0
0.5000    0  0.5000
    0  1.0000    0
```

```
>> T^301
```

```
ans =
```

```
    0  1.0000    0
0.5000    0  0.5000
    0  1.0000    0
```

- Potências ímpares

```
>> T^5
```

```
ans =
```

```
    0  1.0000    0
0.5000    0  0.5000
    0  1.0000    0
```

```
>> T^51
```

```
ans =
```

```
    0  1.0000    0
0.5000    0  0.5000
    0  1.0000    0
```

$$\lim_{n \rightarrow \infty} T^n$$

- Se T é a matriz de transição de um processo de Markov **regular** então:
- $\lim_{n \rightarrow \infty} T^n$ é a matriz:

$$A = \begin{bmatrix} u_1 & u_1 & \cdots & u_1 \\ u_2 & u_2 & \cdots & u_2 \\ \cdots & \cdots & \cdots & \cdots \\ u_N & u_N & \cdots & u_N \end{bmatrix}$$

Com todas as colunas idênticas

- Cada coluna \mathbf{u} é um vector probabilidade

Vector estado estacionário (steady-state vector)

- Sendo T uma matriz de transição regular e \mathbf{u} o resultado anterior, demonstra-se que:

(a) Para qualquer vector de probabilidade \mathbf{x} ,
 $T^n \mathbf{x} \rightarrow \mathbf{u}$ quando $n \rightarrow \infty$

– Sendo \mathbf{u} o vector estado estacionário (**steady-state vector**)

(b) \mathbf{u} é o único vector de probabilidade que satisfaz a equação matricial $T\mathbf{u} = \mathbf{u}$

Cálculo do vector estado estacionário

- Sabemos que o vector correspondente ao estado estacionário é única.
- Usamos a equação que ele satisfaz para o calcular: $\mathbf{T}\mathbf{u} = \mathbf{u}$
- Ou, na forma matricial, $(\mathbf{T} - \mathbf{I})\mathbf{u} = 0$

Exemplo 1 (aulas)

- $\mathbf{T}\mathbf{u} = \mathbf{u}$

- $\begin{bmatrix} 0,7 & 0,8 \\ 0,3 & 0,2 \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \end{bmatrix} = \begin{bmatrix} u_1 \\ u_2 \end{bmatrix}$

- $\begin{cases} \frac{7}{10}u_1 + \frac{8}{10}u_2 = u_1 \\ \frac{3}{10}u_1 + \frac{2}{10}u_2 = u_2 \end{cases} = \begin{cases} \frac{-3}{10}u_1 + \frac{8}{10}u_2 = 0 \\ \frac{3}{10}u_1 + \frac{-8}{10}u_2 = 0 \end{cases}$
 $u_1 + u_2 = 1$

- ...

Em Matlab

Uma possível solução:

```
% matriz de transição
```

```
T=[7 8; 3 2]/10
```

```
% (T-I)u aumentado com  
u1+u2
```

```
M=[T-eye(2);  
    ones(1,2)]
```

```
%
```

```
x=[0 0 1]'
```

```
% resolver para obter u
```

```
u=M\x
```

Resultado:

0.7273

0.2727

Ou seja aprox. 72 % de
probabilidade de não
faltarem

...

- Pode também ser resolvido usando uma matriz aumentada e a função **rref()**

%Matlab

C= [M x]

rref(C)

$$\left(\begin{array}{cc|c} -3/10 & 8/10 & 0 \\ 3/10 & -8/10 & 0 \\ 1 & 1 & 1 \end{array} \right) \rightsquigarrow \left(\begin{array}{cc|c} 1 & 0 & 8/11 \\ 0 & 1 & 3/11 \\ 0 & 0 & 0 \end{array} \right)$$

- Mais informação:
https://www.math.ucdavis.edu/~daddel/Math22al_S02/LABS/LAB2/lab2_w01/node9.html

Exemplo 2

- Aplicando a última técnica ao nosso exemplo 2 (grupos) teremos

$$\left(\begin{array}{ccc|c} -2/3 & 1/4 & 0 & 0 \\ 1/3 & -1/2 & 1/2 & 0 \\ 1/3 & 1/4 & -1/2 & 0 \\ 1 & 1 & 1 & 1 \end{array} \right) \rightsquigarrow \left(\begin{array}{ccc|c} 1 & 0 & 0 & 3/17 \\ 0 & 1 & 0 & 8/17 \\ 0 & 0 & 1 & 6/17 \\ 0 & 0 & 0 & 0 \end{array} \right)$$

Aula 17 - Estados Absorventes + PageRank??

demo

– Absorbing

- <http://demonstrations.wolfram.com/AbsorbingMarkovChain/>

Link Analysis / PageRank

Basear directamente no cap Link
Analysis

VER tb cap Moller

Cerca de 30 slides

Aula 18 –12 Nov

Revisões e exercícios Markov
(Matlab)

Para ajudar a prepararem Miniteste

- Resolver exercícios simples e menos simples
- Resolver algum(ns) do Guião

Exercício 1

Exercício 2